

SOFIAA



AI Experience Middleware

Repensando cómo las organizaciones aprenden, deciden y actúan
a través de inteligencia artificial contextual — Sprints A→H completados

Las organizaciones se ahogan en datos y mueren de sed de sabiduría.

01

Los Datos Existen

Terabytes de datos operativos generados cada día — atrapados en silos, inaccesibles para quienes los necesitan.

02

Los Modelos Existen

Los LLMs razonan a velocidad sobrehumana — pero operan sobre conocimiento estático, desconectados de la realidad.

03

La Brecha

No existe una capa inteligente que conecte datos empresariales en vivo, contexto por rol y lenguaje natural... hasta ahora.

¿Cómo puede un sistema de IA adaptar conocimiento, comportamiento e interfaz en tiempo real según el usuario?




Hipótesis:

Un middleware cognitivo en capas — combinando motores de política, grafos de experiencia, máquinas de estado de objetivos, Agent Runtime ReAct y runtimes de capacidades — puede transformar cualquier LLM en una inteligencia organizacional consciente del rol.

Del Catálogo al Agente Cognitivo

8 fases de investigación — cada una extiende el middleware con nuevas capacidades cognitivas



✓ Sprints A-H completados

7 Capas Cognitivas Integradas

07

Interfaz Adaptativa

Intent-Driven UI · Generative Cards · Onboarding

06

LLM Orchestrator

Groq LLaMA 3.3 70B → Gemini Fallback · Streaming SSE

05

Agent Runtime ReAct ★ NEW

think → act × 3 → synthesize · query_data · search_memory · analyze

04

Motor de Política Cognitiva

8 Políticas · CPE Score 0-1 · Evaluación post-stream

03

Grafo de Experiencia + Memoria

Nodos ponderados · Decaimiento 5%/día · Firestore dual-write ★ NEW

02

Máquina de Estado de Objetivos

Objetivos multi-paso · sessionStorage · Detección automática

01

Capability Runtime

Firestore en vivo · Gateway RBAC · Resúmenes estructurados · BuscarRegistro

Agent Runtime ReAct

Motor de razonamiento iterativo — piensa, actúa y observa hasta sintetizar la respuesta correcta



THINK

Analiza el objetivo
y planifica herramientas



ACT

Ejecuta herramienta
(query_data / analyze)



OBSERVE

Procesa resultado
y actualiza contexto



SYNTHESIZE

Respuesta final
cuando converge

🔄 max 3 iteraciones · fallback si alcanza límite · Edge-safe 8s timeout

Herramientas disponibles:

◆ query_data → Firestore en vivo

◆ search_memory → Contexto + Historial

◆ analyze → Gemini 1.5 Flash

Persistent Intelligence Layer

SOFIAA ya no olvida — memoria a largo plazo multi-dispositivo y datos de pipeline en Firestore

H-1 agentMode

- Detección automática de consultas complejas
- Patrones: analiza, compara, reporte ejecutivo
- Activa ReAct para admin/director/vp

H-2 Memory Store

- Dual-write: localStorage + Firestore
- Sync al autenticarse — cross-device
- `users/{uid}/memory/long_term`

H-3 Pipeline → Firestore

- Cada request → event en Firestore
- `users/{uid}/pipeline_events/{id}`
- Campo date para queries de N.O.R.A

Patrón Dual-Write:

Write → localStorage (inmediato, sin latencia) + Firestore async (persistente, cross-device) → Lee siempre desde localStorage (ya sincronizado)

Datos Empresariales en Vivo — Sin Revelar la Fuente al LLM

1

Pregunta
Natural

2

LLM +
Function Call

3

Gateway
RBAC

4

Data
Provider

5

Summarizer
Estructurado

6

Respuesta
Precisa

60%

Reducción de tokens
vs. inyección JSON completa

0

Alucinaciones
Dato exacto de Firestore

∞

Fuentes soportadas
Firestore · Monday · SAP · REST

TTL

Contexto efímero
Purgado tras cada turno

Capabilities activas:

- ◆ TEC BI: Empleados · Proveedores · Clientes · Briefs · Proyectos · Evaluaciones · Costos · ROI
- ◆ Marketing Sofia: Clientes · Métricas · Calendario · Finanzas | BuscarRegistro (admin) — cross-extension

Instrumentos de Medición de Inteligencia

9.8^{/10}

CPE Policy Score
promedio actual

60%

Reducción tokens
vs. JSON completo


3^{LLMs}

Providers en
orquestador


<2s

P95 latencia
streaming

Complejidad por Sprint (1-10)



Distribución de Tareas



SOFIAA vs. Estado del Arte en IA Empresarial

Capacidad	ChatGPT Ent.	RAG Pipeline	Fine-tuning	SOFIAA
Respuestas por rol (RBAC)	Parcial	No	Parcial	✓ Gateway completo
Datos en tiempo real	No	Parcial	No	✓ Capability Runtime
Contexto temporal usuario	No	No	No	✓ Grafo de Experiencia
Políticas de comportamiento	Básico	No	Entrenamiento	✓ CPE Score 0-1
Agent Runtime iterativo	Parcial	No	No	✓ ReAct 3-step
Memoria persistente	No	No	No	✓ Dual-write Firestore
Pipeline Analytics nativo	No	No	No	✓ N.O.R.A ready

Contribuciones que Avanzan el Estado del Arte

I Inyección de Datos Bajo Demanda

A diferencia de RAG, SOFIAA obtiene datos en vivo de Firestore solo cuando el LLM declara una Function Call. Efímero, controlado por rol, eficiente en tokens.

vs. RAG: recuperación siempre activa

II Grafo de Experiencia Temporal

Grafo ponderado de preferencias que decae con el tiempo — modelando el olvido y reenfoque humano. Ningún framework LLM implementa decaimiento temporal.

Novedad: sin arte previo

III Agent Runtime ReAct Edge-safe

Motor ReAct (Reason+Act) con timeout de 8s, máx 3 iteraciones, streaming a cliente en tiempo real. 3 herramientas: query_data, search_memory, analyze.

vs. LangChain: Edge-native, sin servidor

IV Pipeline Observer → N.O.R.A Dataset

Cada request genera un evento en Firestore con taskType, latencia, proveedor y fecha — construyendo el dataset que N.O.R.A necesita para aprender.

Base de datos de comportamiento real

N.O.R.A

Núcleo de Observación, Razonamiento y Aprendizaje

N.O.R.A es la capa de inteligencia emergente de SOFIAA — el sistema que aprende de patrones reales de uso, construye vectores de comportamiento y hace predicciones operativas antes de que el usuario sepa que las necesita.



BehaviorVector

Computa patrones semanales desde
pipeline_events: taskType dominante, latencia,
extensión preferida, hora pico.



Aprendizaje continuo

Cada evento acumulado en Firestore refina el
perfil. Sin re-entrenamiento — inteligencia por
observación.



Predicciones Proactivas

Anticipa necesidades: 'Notado que los lunes
revisas KPIs — ¿te preparo el resumen?'
Recomendaciones sin preguntar.

Próximos Sprints — Hacia SOFIAA 2.0

Sprint I

Q3 2026

N.O.R.A Core

- BehaviorVector: computa patrones semanales desde pipeline_events
- Análisis por taskType, latencia, extensión, hora pico
- Endpoint /api/hora → responde consultas de comportamiento
- Memory enrichment: añade BehaviorSummary al long_term memory

Sprint J

Q3 2026

Recomendaciones Proactivas

- SOFIAA sugiere sin que el usuario pregunte
- Trigger: horario, patrón de uso, objetivos recurrentes
- Notificaciones push vía Firestore onSnapshot
- Panel de recomendaciones en AdminPanel

Sprint K

Q4 2026

Multi-tenant + Onboarding IA

- Soporte multi-organización — configuración por tenant
- Onboarding conversacional adaptativo por rol
- Exportación de BehaviorVectors para analytics
- API pública: SOFIAA como servicio (SaaS ready)

Sprint L

Q4 2026

Voice + Mobile Native

- Interfaz de voz: Web Speech API + síntesis
- PWA optimizada para coordinadores en campo
- Comandos de voz para Capability Runtime
- Sincronización offline-first con Workbox

Lo que SOFIAA puede hacer cuando N.O.R.A está activa

HOY — Sin N.O.R.A

X Responde cuando el usuario pregunta

X Memoria genérica por usuario

X Routing fijo por proveedor LLM

X Pipeline data en silos de telemetría

X Capabilites siempre disponibles igual

CON N.O.R.A ACTIVA

✓ Sugiere antes de que pregunten

✓ BehaviorVector personalizado por patrón real

✓ Routing predictivo según historial de latencia

✓ Insights semanales automáticos al admin

✓ Capabilities priorizadas por uso real del rol

N.O.R.A transforma SOFIAA de reactiva a proactiva — de herramienta a colega cognitivo.

Impacto Social y Económico

\$655K

Valor IP total
estimaado

3

Verticales
empresariales

15-20h

Horas ahorradas
por semana

∞

Escalable sin
costo adicional

1

Equidad del Conocimiento

Misma calidad de insight para cualquier rol —
filtrado por alcance, no por rango jerárquico.

2

Aumentación Cognitiva


Elimina la fricción de encontrar, interpretar y
contextualizar datos. Más tiempo decidiendo,
menos buscando.

3

Memoria Institucional

El Grafo de Experiencia captura patrones de
interacción y objetivos — inteligencia
organizacional que no se va.

Proyección de usuarios activos



Cinco Axiomas que Rigen Cada Decisión de Diseño

01 El Dato no es Conocimiento

El dato crudo se convierte en conocimiento solo cuando pasa por rol, contexto e intención. SOFIAA nunca expone datos crudos al LLM.

02 El LLM es Razonador, no Almacén

El modelo de lenguaje es un motor de razonamiento. Los datos fluyen mediante canales verificados — nunca en prompts estáticos.

03 La Experiencia debe Decaer

Las señales de interés tienen peso temporal. +0.12 por interacción, decaimiento 5%/día. El grafo modela el olvido humano.

04 El Acceso es un Derecho Gobernado

Cada capacidad está protegida por RBAC en el Gateway. El LLM nunca decide quién puede ver qué — la política lo decide.

05 Cada Turno Mejora el Sistema

Cada conversación actualiza el Grafo, informa al CPE y refina el perfil. N.O.R.A aprende de cada evento acumulado.

El futuro de la IA empresarial no son modelos más inteligentes — es un middleware más inteligente.



SOFIAA demuestra que una arquitectura cognitiva en capas — motores de política, grafos de experiencia, máquinas de objetivo, Agent Runtime ReAct y runtimes de capacidades — puede transformar cualquier LLM en una inteligencia organizacional consciente del rol, a una fracción del costo del fine-tuning.

Con N.O.R.A, SOFIAA deja de ser reactiva para volverse proactiva — el primer AI Experience Middleware que aprende de su propia operación.

Intent-Driven UI

LLM Orchestrator

ReAct Runtime

CPE Score

Experience Graph

Capability Runtime

N.O.R.A Ready