

S O F I A A

Sistema Operativo de Facilitacion Inteligente para Interaccion y Acompañamiento

Reporte Tecnico Ejecutivo | Fase 2 Alpha Hardening

Preparado por: Abraham Cruz Urrutia (Benjacob)

Junio 2026 | SOFIAA LAB | Monterrey, Mexico

01. Resumen Ejecutivo

SOFIAA es un IX-OS (Intelligent Experience Operating System) desarrollado en Monterrey, Mexico por Abraham Cruz Urrutia. No es un chatbot convencional: es una capa cognitiva que transforma la manera en que las personas interactuan con informacion, servicios y decisiones.

El proyecto combina tecnologia de lenguaje natural de ultima generacion (Groq / LLM) con una arquitectura de tres capas de memoria, telemetria en tiempo real, y una experiencia visual de clase mundial inspirada en el estetica Apple y sistemas como JARVIS.

Estado Actual

Fase 2 Alpha Hardening completada. Sprint 2.8 (Pre-deploy) en ejecucion. El sistema esta listo para su primer deploy a Vercel.

Sprints Completados

Sprint	Nombre	Entregables clave
0	Paginas internas	Rutas /servicios, /quienes-somos, /contacto con backbutton
2.0	Core + Streaming	Groq API, streaming SSE, Neural Orb SVG, bienvenida animada
2.1	Architecture Freeze	Documentacion tecnica, congelamiento de arquitectura
2.2	Guardrails & Seguridad	Motor de amenazas, doble validacion cliente+servidor, 5 tipos de ataque
2.3	Telemetria + Panel Cognitivo	KPIs TTI/IFC/CVR/CKS, dashboard con graficas SVG, frase 'modo analisis'
2.4	Response Cache	Normalizacion de intencion, stopwords, TTL por categoria, flash cyan
2.5	Goal Engine	8 tipos de objetivo, rutas de prompt por meta, deteccion de intencion
2.6	Memory Timeline	3 capas de memoria, historial de sesiones, reanudacion de contexto
2.7	Visual Intelligence	OrbController, ExperienceDisclosure, estados transitorios, Admin Panel
2.8	Pre-deploy Hardening	Fix TypeScript, SEO metadata, verificacion .env, preparacion Vercel

02. Stack Tecnologico

Frontend

Tecnologia	Uso en SOFIAA
Next.js 15 (App Router)	Framework principal. SSR + rutas de API + streaming nativo
TypeScript	Tipado estricto en todo el proyecto. 0 errores en build final
Tailwind CSS v4	Estilos con @theme inline. Sin archivo tailwind.config.ts
React 19	Hooks, refs, estado local. Sin Redux ni Zustand
ReactMarkdown + remark-gfm	Renderizado de respuestas con formato Markdown
Web Speech API	SpeechRecognition (voz a texto) + SpeechSynthesis (texto a voz)

Backend & API

Tecnologia	Uso en SOFIAA
Groq API	Motor LLM. Compatible con SDK OpenAI
openai/gpt-oss-120b	Modelo principal de chat y razonamiento
openai/gpt-oss-20b	Modelo ligero para extraccion de memoria
Next.js Route Handlers	Endpoints /api/chat y /api/memory con SSE
Server-Sent Events (SSE)	Streaming en tiempo real de respuestas token a token

Arquitectura de Modulos

Modulo	Responsabilidad
guardrails.engine.ts	Deteccion y bloqueo de 5 tipos de amenaza (inyeccion, jailbreak, etc.)
response-cache.ts	Cache con normalizacion NFC/stopwords y TTL por categoria
goal.engine.ts	Deteccion de 8 objetivos de usuario. Inyecta contexto en el prompt
memory.timeline.ts	Historial de ultimas 20 sesiones. Contexto en 3 capas
experience.disclosure.ts	Revelacion progresiva de UI segun estado cognitivo del orbe
orb.controller.ts	Maquina de estados del orbe con auto-retorno a idle

<code>useSofiaaTelemetry.ts</code>	Hook de telemetria: TTI, IFC, CVR, CKS, guardrails, voz
<code>system.prompt.ts</code>	Kernel de personalidad, contexto, navegacion y memoria de SOFIAA

03. Capacidades de SOFIAA

Comunicacion e Interaccion

- Conversacion en lenguaje natural en cualquier idioma — responde siempre en el idioma del usuario
- Entrada por texto y por voz (microfono nativo del navegador via Web Speech API)
- Salida por texto con formato Markdown (negrita, listas, codigo) y por voz sintetizada
- Streaming token a token — las respuestas aparecen en tiempo real sin esperar al final
- Quick Actions: accesos rapidos configurables para preguntas frecuentes
- Bienvenida dinamica: saludo rotativo personalizado al cargar la aplicacion

Memoria e Identidad

- Memoria Operativa: contexto de la sesion activa completa en el prompt
- Memoria Contextual: ultimas 5 sesiones inyectadas como bloque de contexto en cada conversacion
- Memoria Historica: resumen de largo plazo (sofiaa_long_memory) que persiste entre sesiones
- Timeline de sesiones: historial de hasta 20 sesiones con titulo, fecha, tags y objetivo principal
- Reanudacion de sesion: el usuario puede reanudar el contexto de cualquier sesion anterior
- Extraccion de memoria: SOFIAA genera automaticamente resumen, titulo y tags al cerrar sesion

Inteligencia Contextual

- Goal Engine: detecta 8 tipos de objetivo (informarse, comparar, aprender, decidir, contactar, contratar, navegar, general)
- Instrucciones adaptativas: inyecta contexto especifico al prompt segun el objetivo detectado
- Protocolo cognitivo JARVIS: SOFIAA analiza cada mensaje en 4 pasos internos (recepcion, comprension, anticipacion, resolucion)
- Proactividad: ofrece pasos siguientes e ideas adicionales sin que el usuario las pida
- Navegacion interna: puede llevar al usuario a /servicios, /quienes-somos o /contacto con aviso previo

Seguridad

- Doble validacion: guardrails en cliente (antes del fetch) y en servidor (en el route handler)
- 5 tipos de amenaza detectados: inyeccion de prompt, extraccion de secretos, fuga de contexto, jailbreak, abuso
- Bloqueo acumulativo: tras 3+ intentos de seguridad en la misma sesion, bloquea la conversacion
- Respuestas de seguridad randomizadas: 5 variantes por tipo de amenaza para evitar patrones predecibles
- Log de eventos de seguridad en servidor (solo server-side, nunca expuesto al cliente)

Rendimiento y Cache

- Cache de respuestas con normalizacion de intencion: NFD + minusculas + stopwords + orden + truncado a 120 chars
- TTL por categoria: identidad/servicios 7 dias, navegacion/saludo sin cache, resto 1 hora
- Flash visual de cache hit: orbe cambia a cyan 1.2s para indicar respuesta instantanea
- Telemetria de KPIs: TTI (tiempo de respuesta), IFC (longitud promedio), CVR (uso de quick actions), CKS (memoria activa)

Experiencia Visual

- Neural Orb: esfera SVG con 30 neuronas y 46 conexiones animadas, hemisferios izquierdo (azul) y derecho (rosa)
- 7 estados visuales del orbe: idle, listening, thinking, responding, cache_hit, error, success
- Experience Disclosure: revelacion progresiva de elementos UI segun el estado cognitivo — la interfaz respira
- Estetica Apple liquid glass: fondos translucidos con blur, gradientes sutiles, sombras suaves
- 4 paginas: / (main OS), /servicios, /quienes-somos, /contacto — todas con BackButton

Administracion

- Panel de admin oculto: frase secreta 'espada del augurio' activa el panel
- Frases secretas adicionales: 'modo analisis' abre el panel de metricas
- Timeline de sesiones con expand/collapse y boton de reanudacion de contexto
- Panel Cognitivo (CognitiveDashboard): TTI sparkline, ratios globales, guardrails count
- Panel de metricas (/metricas): 6 KPI cards, graficas SVG, estadisticas de cache, glosario tecnico

04. Analisis de Riesgos

La siguiente tabla presenta el analisis de riesgos del sistema SOFIAA bajo el modelo de Gestion de Riesgos con evaluacion de Gravedad (impacto si ocurre) y Probabilidad de ocurrencia, junto con el plan de mitigacion recomendado.

Nivel	Gravedad	Probabilidad	Interpretacion
ALTA	Impacto critico en usuario o sistema	Ocorre con frecuencia o facilmente	Accion inmediata requerida antes del deploy
MEDIA	Degradacion notable de experiencia	Puede ocurrir bajo ciertas condiciones	Planificar mitigacion en siguiente sprint
BAJA	Impacto menor, no critico	Poco probable o muy especifico	Monitorear. Mitigar si crece en incidencia

ID	Area	Riesgo	Gravedad	Probabilidad	Mitigacion
R01	API / Backend	Groq API key expuesta en codigo	Alta	Baja	Verificar .gitignore antes de cada push. Usar git-secrets o similar. Rotar la key inmediatamente si se expone.
R02	API / Backend	Agotamiento de tokens Groq (rate limit)	Alta	Media	Implementar rate limiting por IP en el route handler. Agregar limite de mensajes por sesion (ej. 50 msgs/hora).
R03	Seguridad	Bypass de guardrails con tecnicas avanzadas	Alta	Media	Agregar validacion semantica (LLM-as-judge) adicional a los regex. Actualizar patrones regularmente. Log y monitoreo.
R04	Memoria	Corrupcion de localStorage (memoria historica)	Media	Media	Agregar try/catch en todas las lecturas de localStorage. Implementar schema version + auto-reset si el parse falla.
R05	Experiencia	Navegacion automatica sin aviso en navegadores lentos	Media	Baja	Esperar a que el mensaje sea visible antes de iniciar el contador. Alternativa: mostrar barra de progreso de redireccion.
R06	Experiencia	Orbe atascado en estado 'thinking'	Media	Media	Agregar timeout de 30s al fetch. Si el stream no recibe datos en 15s, disparar orb.showError() y mostrar mensaje de reintento.

R07	Compatibilidad	Web Speech API no disponible en todos los navegadores	Baja	Alta	El boton de voz ya verifica si la API existe antes de mostrarse. Agregar mensaje explicativo si no esta disponible.
R08	Compatibilidad	Backdrop-filter no soportado en algunos navegadores	Baja	Baja	Ya existe @supports en el CSS. El fallback es fondo blanco solido. Funcional aunque sin efecto visual premium.
R09	Performance	Cache sin limite de entradas en localStorage	Baja	Media	Implementar LRU eviction: eliminar las entradas mas viejas cuando se superen N entradas o X KB de cache.
R10	Contenido	SOFIAA navega a pagina interna sin que el usuario lo pida	Media	Media	La regla del system prompt ya instruye solo navegar cuando el usuario 'claramente quiere ver esa seccion'. Monitorear y ajustar el prompt si persiste.
R11	Deploy	Variables de entorno no configuradas en Vercel	Alta	Media	Verificar las env vars en Vercel antes del primer deploy. Agregar manejo de error claro cuando la key falta en el servidor.
R12	Deploy	Memoria perdida entre deploys en Vercel	Media	Alta	Documentar claramente que la memoria es local al navegador. Fase 3 deberia implementar sincronizacion en la nube (Supabase, etc.).

05. Proximos Pasos

Inmediato — Sprint 2.8 (Esta semana)

- Subir cambios a GitHub y hacer push del ultimo estado
- Crear proyecto en Vercel e importar el repositorio
- Configurar GROQ_API_KEY en las variables de entorno de Vercel
- Primer deploy a produccion y verificacion funcional

Fase 3 — Evolucion del Sistema

- Autenticacion de usuario: login con Google/Apple para proteger el acceso
- Memoria en la nube: sincronizar memoria historica via Supabase o similar
- Rate limiting real: middleware en Vercel Edge para limitar requests por IP
- Custom favicon y og:image con identidad de marca SOFIAA
- Dominio personalizado: sofiaa.abrahan.mx o similar
- Alertas de errores: integrar Sentry para monitoreo en produccion
- Voz mejorada: integrar ElevenLabs o Azure TTS para voz mas natural que el Web Speech API
- Multimodalidad: soporte para imagenes y archivos en la conversacion

SOFIAA LAB | Monterrey, Mexico | 2026

Creado por Abraham Cruz Urrutia (Benjacob)